




Preprocesamiento & Transformación de datos

Ing. Juan M. Rodríguez
jmrodriguez@lsia.fi.uba.ar

Proceso de KDD (Knowledge Discovery in Databases)



Hoy nos vamos a enfocar en las etapas de Preprocesamiento y Transformación


Preprocesamiento & Transformación



Algunas tareas de estas etapas son:

- ***Integración de datos:*** Integración de múltiples bases de datos, archivos, etc.
- ***Limpieza de datos:*** Completar valores faltantes, eliminación de ruido, identificar o eliminar valores atípicos y corregir incoherencias
- ***Reducción de datos:*** Reducción de dimensionalidad, Reducción de Numerosidad
- ***Transformación de datos:*** Normalizaciones, generación de jerarquías conceptuales, etc. (Feature Engineering)


Preprocesamiento & Transformación



Hoy nos vamos a enfocar en las etapas de Preprocesamiento y Transformación


Limpieza de datos

Limpieza de datos



Y una lista infinita...

Limpieza de datos



Limpieza de datos

Datos faltantes

Tipos de datos faltantes



Clasificación de Rubin (1976)

- ***Missing completely at random MCAR*** : significa que la razón por la cual el dato no está es completamente aleatoria, y que probablemente no podamos predecir el valor a partir de otro valor en los datos.
- ***Missing At Random MAR***: los datos faltantes pueden ser explicados por valores en las otras columnas, pero no por valores de esa columna. Por ejemplo, si cada columna representa una elección excluyente
- ***Missing Not At Random MNAR***: significa que es probable que la falta de ese dato no sea al azar. En este caso tenemos que investigar la causa por la que falta ese valor.

Tipos de datos faltantes



Missing completely at random MCAR

- La probabilidad de valores faltantes es la misma para todas las observaciones.
- No existe ninguna relación entre los datos faltantes y otros valores observados o faltantes en el dataset.
- Omitir estas observaciones no implicaría un sesgo en las inferencias.
- Ejemplo: Se perdió la respuesta de una encuesta

Tipos de datos faltantes



Missing Not At Random MNAR

Existe una explicación por la cual hay valores faltantes en un dataset.

Ejemplos:

En una encuesta sobre salarios, los participantes con mayor nivel de ingresos se ven menos inclinados a reportarlos.

En un estudio sobre depresión, los pacientes con depresión son menos propensos a responder algunas preguntas.

Tipos de datos faltantes



Missing At Random MAR

- La probabilidad de datos faltantes en una observación no está relacionada con los datos faltantes, pero puede depender de la información que sí está disponible. Es decir, el azar no es la única causa por la que faltan esos datos.
- Ejemplo: En un estudio para un nuevo tratamiento, algunos sujetos se retiran cuando empiezan a tener efectos secundarios

Tipo de dato faltante	Definición	Ejemplo
MAR (Faltante al Azar)	La falta de datos no es aleatoria, pero la probabilidad de falta de datos se puede explicar por otras variables observadas	Una encuesta pregunta por los ingresos de los encuestados y si asistieron a una universidad privada o pública. Los encuestados que asistieron a universidades privadas son más propensos a ocultar sus ingresos, pero esto se puede explicar por la variable "tipo de universidad".
MCAR (Faltante Completamente al Azar)	La falta de datos es completamente aleatoria y la probabilidad de falta de datos no depende de ninguna variable observada o no observada	Un fallo informático eliminó al azar algunas filas de un conjunto de datos.
MNAR (Faltante No al Azar)	La falta de datos no es aleatoria y la probabilidad de falta de datos depende del valor faltante en sí	En un estudio médico, los participantes con síntomas más graves son menos propensos a completar las encuestas de seguimiento, lo que lleva a datos faltantes que no son aleatorios.

Estrategias para trabajar con datos faltantes



Entender el motivo de ausencia de los datos permite seleccionar una estrategia adecuada para su tratamiento.

Eliminar registros o variables

Si la eliminación de un subconjunto disminuye significativamente la utilidad de los datos, la eliminación del caso puede no ser efectiva (No se recomienda en situaciones que no sean MCAR)

Imputar datos

Utilizar métodos de relleno de faltantes.

Imputación de datos faltantes



- La imputación es el acto de reemplazar datos faltantes con estimaciones estadísticas de los valores ausentes.
- El objetivo de cualquier técnica de imputación es producir un dataset completo que permita entrenar un modelo de aprendizaje automático.
- Pueden agruparse las técnicas de imputación en dos categorías:
 - Univariada:** cuando la imputación se realiza de manera independiente para cada variable de entrada, sin considerar las otras variables.
 - Multivariada:** cuando el valor imputado para cada variable es una función de dos o más variables

Imputación de datos faltantes



Algunas técnicas de imputación univariada (por tipo de variable al que aplican):

- Variables numéricas:

- ☐ Imputación por promedio/mediana.
- ☐ Imputación por valor arbitrario.
- ☐ Imputación de “fin de cola” (end of tail).

- Variables categóricas:

- ☐ Imputación por categoría frecuente.
- ☐ Agregar categoría “FALTANTE”.

- Ambas:

- ☐ Análisis de caso completo.
- ☐ Agregar indicador “FALTANTE”.
- ☐ Imputación por muestreo aleatorio.

Imputación de datos



Sustitución de casos

Se reemplaza con valores no observados.

Debería ser realizado por un experto en esos datos

Sustitución por Media o Mediana

Se reemplaza utilizando la medida calculada de los valores presentes.

Algunas desventajas:

- La varianza estimada de la nueva variable no es válida porque está atenuada por los valores repetidos
- Se distorsiona la distribución
- Las correlaciones que se observen estarán deprimidas debido a la repetición de un solo valor constante


Imputación de datos

Imputación Cold Deck

Selecciona valores o usa relaciones obtenidas de fuentes distintas de la base de datos actual

lat	lon	ciudad	barrio
-34.607269	-58.375478	Capital Federal	NaN
-34.607269	-58.375478	Capital Federal	NaN
-34.625486	-58.455938	Capital Federal	NaN
-39.261539	-68.779088	Capital Federal	NaN
-38.827752	-68.144293	Capital Federal	NaN

Fuente de datos original: Properati



Fuente para imputación: capas geográficas provistas por GCBA

Imputación de datos

Imputación Hot Deck

Se reemplazan los faltantes con valores obtenidos de registros que son los más similares.

(Hay que definir que es similar, K vecinos más cercanos puede servir)

	rooms	bathrooms
214	3.0	NaN
253	3.0	NaN
383	5.0	NaN
486	3.0	NaN
927	1.0	NaN

Podría pensar en definir registros similares como otros inmuebles con la misma cantidad de ambientes (rooms), y completar la variable bathrooms con el valor más probable en ellos

Fuente de datos original: Properati

Imputación de datos

Imputación por regresión

El dato faltante es reemplazado con el valor predicho por un modelo de regresión

bedrooms	surface_total	property_type	rooms
7.0	640.0	Casa	NaN
7.0	1309.0	Casa	NaN
1.0	45.0	Casa	NaN
8.0	320.0	Casa	NaN
2.0	230.0	Casa	NaN

Podría pensar en predecir la variable rooms en función de la cantidad de habitaciones, la superficie total del inmueble y el tipo de inmueble

Imputación de datos



MICE - Multivariate Imputation by Chained Equations

Trabaja bajo el supuesto de que el origen de los faltantes es Missing At Random (MAR)

Es un proceso de imputación de datos faltantes iterativo, en el cual, en cada iteración cada valor faltante de cada variable se predice en función de las variables restantes.

Esta iteración se repite hasta que se encuentre convergencia en los valores. No es tan sencillo determinar la condición de convergencia.

Imputación de datos

MICE - Multivariate Imputation by Chained Equations

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.95	1.24	1.46
0.23	0.57	
0.90		1.28
0.15	0.42	
0.47	0.54	0.63
0.89	1.23	1.45

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.90	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	0.46	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.47	1.14	1.28
0.89	1.23	1.45

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.24	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	0.46	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.89	1.14	1.28
0.89	1.23	1.45

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.24	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	1.24	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.89	1.14	1.28
0.89	1.23	1.45

El método inicia el dataset original, con los datos faltantes


En cada dato faltante se imputa un valor utilizando por ejemplo alguno de los métodos vistos antes

Con las variables B y C, se genera un modelo para redecir los faltantes originales en la variable A

Con las variables A y C, se genera un modelo para redecir los faltantes originales en la variable B

Continúa...

Multiple Imputation by Chained Equations (MICE) – Single Iteration



Transformación de datos

Feature Engineering

Feature Engineering



Esta etapa incluye cualquier proceso de modificación de la forma de los datos (es común que los datos sufran algún tipo de transformación)

El objetivo principal de esta etapa es mejorar el rendimiento de los modelos creados mediante la transformación de los datos que utilizan

Feature Engineering



Algunas técnicas son:

- Normalización
- Discretización
- Lograr normalidad
- Imaginación (Generación de nuevas variables)

Normalización



Se aplica sobre valores numéricos

Consiste en **escalar los features** de manera que puedan ser mapeados a un rango más pequeño.

Por ejemplo: 0 a 1 o -1 a 1

Es principalmente utilizada cuando:

- Las unidades de medidas dificultan la comparación de features.
- Se quiere evitar que atributos con mayores magnitudes tengan pesos muy diferentes al resto

Normalización - Min Max



Funciona al ver cuánto más grande es el valor actual del valor mínimo del feature y escala esta diferencia por el rango

$$X_{mm}^* = \frac{X - \min(X)}{\text{range}(X)} = \frac{X - \min(X)}{\max(X) - \min(X)}$$

Los valores de normalización min-max van de 0 a 1

Normalización - Z score



Los valores para un atributo se normalizan en base a su media y desvío estándar

$$Z-score = \frac{X - mean(X)}{sd(X)}$$

Es útil cuando el verdadero mínimo y máximo del atributo no son conocidos, o cuando hay valores atípicos que dominan la normalización min-max.

Normalización - Decimal scaling




Asegura que cada valor normalizado se encuentra entre - 1 y 1.




$$X_{decimal} = \frac{X}{10^d}$$

Donde **d** representa el número de dígitos en los valores de la variable con el valor absoluto más grande



Normalización



Normalización



Transformaciones para lograr normalidad



Podemos reducir este sesgo a partir de transformaciones, por ejemplo:

- Raíz cuadrada
- Logaritmos
- Inversa de la raíz cuadrada
- Transformaciones de Box-Cox

Discretización



Es una técnica que permite dividir el rango de una variable continua en intervalos.

Se reducen los valores de una variable continua a un número reducido de etiquetas

Discretización - Binning



Se divide a la variable en un número específico de **bins**

Los criterios de agrupamiento pueden ser por ejemplo:


- Igual-Frecuencia: La misma cantidad de observaciones en un bin
- Igual-Ancho: Definimos rangos o intervalos de clases para cada bin
- Cuantiles: Separar en intervalos utilizando Mediana, Cuantiles, Percentiles.

Discretización - Binning

A su vez para cada uno de los agrupamientos podemos hacer:

- Reemplazo por media o mediana
- Reemplazo por una etiqueta o valor entero

Igual ancho




Igual frecuencia




Discretización - Binning




Ejemplos en el dataset de Properati



Igual frecuencia



Igual ancho de intervalo




Cuartiles

Variables Dummies – One Hot Encoding

Algunos métodos analíticos requieren que las variables predictoras sean numéricas

Cuando tenemos categóricos, podemos recodificar la variable categórica en una o más **variables Dummies**




property_type	property_type_casa	property_type_dpto	property_type_ph
departamento	0	1	0
casa	1	0	0
casa	1	0	0
ph	0	0	1
departamento	0	1	0
casa	0	0	0

property_type	property_type_casa	property_type_dpto
departamento	0	1
casa	1	0
casa	1	0
ph	0	0
departamento	0	1
casa	0	0

Generación de nuevas variables

Feature Engineering también es crear variables nuevas



Por ejemplo:
Sumar fuentes de información para calcular la distancia desde un inmueble en venta al espacio verde más cercano
