

Ejercicio

Responda las siguientes preguntas respecto al **TP1**:

- ¿Qué técnicas utilizó para detectar **outliers multivariados**? Dar un ejemplo concreto y mencionar qué decisiones se tomaron sobre los casos detectados.
- Describa brevemente una técnica de **preprocesamiento de datos** aplicada en el TP1 y dé un ejemplo concreto de aplicación en el trabajo práctico.

Ejercicio

Explique brevemente los conceptos de **Overfitting** y **Underfitting**. Mencione cómo puede detectarse cada una de estas situaciones y qué se podría hacer para evitarlas.

Ejercicio

Explique de forma breve: ¿Para qué se utiliza el método backpropagation? ¿Qué tipo de método es, es decir que recurso matemático utiliza?

Ejercicio

Se tiene un conjunto de datos de 300 filas y 10 columnas y se quiere entrenar un árbol de decisión para resolver un problema de clasificación. Se genera un conjunto de entrenamiento (80%) y un conjunto de test (20%) y se quiere evaluar la performance del modelo en entrenamiento utilizando k-fold cross validation con k=5. Determinar si las siguientes afirmaciones son verdaderas o falsas:

- Habrán 240 registros que estarán 4 veces en un conjunto de entrenamiento y 1 vez en un conjunto de validación. ☐
- Se partirá el conjunto de entrenamiento en 5 subconjuntos, luego cada subconjunto se partirá con proporción 80/20 para entrenar y validar el árbol. ☐
- El árbol de decisión se entrenará 5 veces. ☐
- No se puede utilizar k-fold cross validation para evaluar el entrenamiento, es un método para optimizar hiperparámetros. ☐

Ejercicio

Indicar si las siguientes afirmaciones sobre **árboles de decisión** son verdaderas o falsas

- Un árbol ID3 se construye utilizando la fórmula de entropía de la información, mientras que un árbol C4.5 se construye utilizando la impureza de Gini ☐
- En un Random Forest tradicional tengo un bosque de tocones (Stumps) ☐
- Los árboles sólo pueden manejar variables numéricas normalizadas ☐
- La técnica de poda se utiliza en los árboles C4.5 para evitar el underfitting. ☐

Ejercicio

Para un proyecto de ciencia de datos, se entrena un modelo predictivo y se evalúa su performance con la métrica F1-Score. Se obtienen los siguientes resultados:

-F1-Score en entrenamiento: 0.25

-F1-Score en test: 0.4

Indique si las siguientes afirmaciones son verdaderas o falsas (V / F):

- El modelo generaliza muy bien para datos nuevos. ☐

- b) El modelo podría estar sobreajustando a los datos de entrenamiento (overfitting).
- c) Hay un problema en los datos de test, se debería evaluar en otro conjunto.
- d) El modelo podría estar subajustando a los datos de entrenamiento (underfitting).

Ejercicio

Indique cuáles de las siguientes afirmaciones son verdaderas:

- Cuando dos variables tienen alto índice de correlación significa que existe causalidad (una causa a la otra).
- Las variables cuantitativas pueden ser discretas o continuas.
- En un problema de clasificación la variable dependiente es cuantitativa.
- En un problema de regresión lineal se busca predecir un valor en un rango continuo.
- En un problema de clustering se trata de agrupar los datos en N conjuntos distinguibles, y siempre se sabe que significan esos conjuntos.

Ejercicio

Se entrenó un modelo de clasificación (MODELO A) para detectar personas enfermas (clase 1) y sanas (clase 0). Luego se evaluó el modelo en los datos de test y se obtuvo la siguiente matriz de confusión:

True	0	135	36
	1	38	111
		0	1
		Predicted	

Se pide:

- a) Calcular la métrica Precision: 0,755
- b) Calcular la métrica Recall: 0,744
- c) Se entrenó un segundo modelo de clasificación (MODELO B), se evaluó sobre los mismos datos de test y se obtuvieron los siguientes resultados:

True Positive: 49
True Negative: 130
False Positive: 41
False Negative: 100

¿Qué modelo (A o B) elegiría en términos de Accuracy? : 0,769